

✉ dstndiaye@gmail.com

☎ 07 58 64 47 06

Diplômes et Formations

● Master Informatique – Machine Learning pour la Science des Données (MLSD)

2024 – 2026

Université de Paris Cité Paris
Deep Learning, NLP, RAG, séries temporelles, systèmes de recommandation, Big Data.

● Licence Mathématiques et Applications

2022 – 2024

Université de Paris Cité Paris
Probabilités, Statistiques, Programmation Orientée Objet (POO / Java), Réseaux et Sécurité informatique.

● Licence Mathématiques et Informatique Appliquées

2019 – 2022

Université Cheikh Anta Diop de Dakar (UCAD) Dakar, DK, Senegal

Algèbre, Analyse, Cryptographie, Programmation Orientée Objet, Développement Web(HTML, CSS), Réseaux.

Compétences

Langages

Python, SQL, R, Java, C

Data Science, Machine & Deep Learning

Pandas, NumPy, Scikit-learn, TensorFlow, Keras, classification supervisée clustering, SVM, Naive Bayes, Stacking Classifier, analyse de graphes.

IA générative, NLP & RAG

Hugging Face, OpenAI API, Mistral AI, LangChain, RAG, Prompt Engineering, FAISS, expressions régulières (Regex), spaCy, NLTK

Qualités

Capacité d'adaptation, autonomie, esprit d'équipe, gestion de projet

Réseaux sociaux

 LinkedIn

 Github

Serigne Bassirou NDIAYE

Data Scientist

Data Scientist avec une expérience en Machine Learning, NLP et IA générative, je recherche un poste en CDI afin de contribuer au développement de solutions d'intelligence artificielle répondant à des problématiques métiers.

Expériences professionnelles

● Data Scientist en alternance

Sept. 2025 – Sept. 2026

Caisse des Dépôts (CDC) – Direction de l'innovation et de la prospective (DIP) Paris

Classification automatique de courriers administratifs

Technologies : Python, Pandas, NumPy, Scikit-learn, TF-IDF, NLP, OCR, Dataiku, SVM, Naive Bayes, Stacking Classifier.

- Préparation des données : nettoyage, filtrage et intégration de nouvelles catégories métiers.
- Entraînement, comparaison et livraison de nouveaux modèles adaptés à l'évolution des données.
- Maintenance et amélioration continue d'un **pipeline de classification multiclasse** de courriers administratifs basé sur le **NLP** et le **Machine Learning**.
- Migration du pipeline sur **Dataiku** pour faciliter le réentraînement, l'exploitation et le suivi des modèles.
- Développement d'une solution d'extraction de données par **OCR** sur des formulaires administratifs.

Projet RAG d'assistance à la recherche documentaire.

Technologies : Python, LangChain, Mistral, FAISS, BGE-M3, LLM, Prompt Engineering.

- Conception d'un système **RAG** destiné à faciliter la recherche d'informations dans une base documentaire interne.
- Structuration de **deux bases de connaissances** : historique de demandes/réponses et documentation métier de référence.
- Mise en place d'une **recherche sémantique** basée sur les embeddings **BGE-M3** et l'indexation vectorielle avec **FAISS**.
- Conception du prompt permettant de générer une réponse conceptualisée à partir des documents disponibles.

Analyse documentaire par IA générative

Technologies : Mistral AI, Large Language Models (LLMs), Prompt Engineering.

- Accompagnement des équipes métier dans l'utilisation de **LLM** pour analyser et synthétiser des dossiers d'appels d'offres.
- Conception et optimisation de **prompts** adaptés aux critères d'analyse métier.
- Expérimentation et comparaison de différentes stratégies de prompting : **Few-Shot**, **Chain-of-Thought**, **Tree-of-Thoughts** et **Chain-of-Draft**.
- Analyse comparative des réponses générées afin d'améliorer la précision, la cohérence et la qualité des synthèses.
- Animation d'ateliers de formation sur l'utilisation des LLM et les bonnes pratiques du **Prompt Engineering**.

● Stagiaire Data Scientist

Juil. 2025 – Sept. 2025

Caisse des Dépôts (CDC) – Direction de l'innovation et de la prospective (DIP) : Paris

Traitement documentaire, OCR et extraction automatique de données

Technologies : Python, PyMuPDF, OCR, Pandas, Dataiku, Machine Learning, NLP, Tesseract.

- Développement d'une solution de **traitement de formulaires administratifs numérisés** : extraction de texte, détection et correction de l'orientation des pages, puis récupération de données structurées avec **PyMuPDF** et **OCR**.
- Prise en main et analyse d'un **pipeline de classification automatique** de courriers basé sur des techniques de **NLP** et de **Machine Learning**.
- Formation à **Dataiku** et obtention de **6 certifications** autour de la Data Science, du Machine Learning, du **MLOps** et de l'**IA générative**.